

Análisis Discriminante Lineal (LDA) y Cuadrático (QDA): Fundamentos Teóricos y Comparación Práctica sobre el Wine Dataset

Odeth Espinoza Feijoo | Universidad de Guayaquil | CDDEIA-ELNO | Métodos Numéricos / Machine Learning

1. Introducción

El análisis discriminante es un conjunto de técnicas estadísticas de aprendizaje supervisado utilizadas para clasificar observaciones en grupos o categorías previamente conocidas, a partir de un conjunto de variables predictoras. A diferencia de otros métodos de clasificación, el análisis discriminante parte de un modelo probabilístico explícito: asume una distribución de las variables predictoras dentro de cada clase (habitualmente normal multivariante) y, mediante el teorema de Bayes, estima la probabilidad de que una observación pertenezca a cada clase, asignándola finalmente a la de mayor probabilidad a posteriori (James, Witten, Hastie y Tibshirani, 2021).

El objetivo de un modelo discriminante es encontrar una función —lineal o cuadrática, según el método— que combine las variables predictoras de forma que separe de la mejor manera posible a las distintas clases presentes en los datos, minimizando el error de clasificación. En términos geométricos, esta función define una frontera de decisión en el espacio de las variables predictoras que divide dicho espacio en regiones asociadas a cada clase.

La diferencia fundamental entre clasificación y regresión radica en la naturaleza de la variable respuesta. En regresión, la variable objetivo es continua y el modelo busca predecir un valor numérico (por ejemplo, el precio de una vivienda). En clasificación, en cambio, la variable objetivo es categórica o discreta, y el modelo busca asignar cada observación a una de un conjunto finito de clases (por ejemplo, el cultivar de un vino). LDA y QDA son, precisamente, métodos de clasificación: aunque internamente estiman probabilidades continuas, su salida final es una etiqueta de clase (Hastie, Tibshirani y Friedman, 2009).

2. Análisis Discriminante Lineal (LDA)

2.1 Definición

El Análisis Discriminante Lineal (LDA, por sus siglas en inglés) es un método de clasificación supervisada que modela la distribución de las variables predictoras dentro de cada clase como una normal multivariante, asumiendo que todas las clases comparten la misma matriz de covarianza. A partir de esta suposición, LDA deriva funciones discriminantes lineales que permiten calcular, para cada observación, la clase con mayor probabilidad a posteriori según el teorema de Bayes.

2.2 Supuestos estadísticos

LDA se basa en tres supuestos principales: (1) las variables predictoras siguen, dentro de cada clase, una distribución normal multivariante; (2) todas las clases comparten una única matriz de covarianza (homocedasticidad multivariante); y (3) las observaciones son independientes entre sí. Cuando estos supuestos se cumplen razonablemente, LDA proporciona el clasificador óptimo desde el punto de vista bayesiano (James et al., 2021).

2.3 Matriz de covarianza compartida

Que las clases compartan la misma matriz de covarianza significa que, aunque cada clase puede tener una media distinta (un centro distinto en el espacio de variables), la forma, orientación y dispersión de la nube de puntos alrededor de esa media es igual para todas las clases. En la práctica, esta matriz de covarianza común suele estimarse como un promedio ponderado de las matrices de covarianza muestrales de cada clase.

2.4 Construcción de la función discriminante

A partir del teorema de Bayes, la probabilidad de que una observación x pertenezca a la clase k es proporcional al producto de la probabilidad a priori de esa clase y la densidad normal multivariante evaluada en x . Al asumir una covarianza común Σ para todas las clases, y tomar el logaritmo de dicha expresión, los términos cuadráticos en x se cancelan entre clases, quedando una función discriminante lineal en x para cada clase k , que depende de la media de la clase, la covarianza común y la probabilidad a priori de la clase. La observación se clasifica en la clase cuya función discriminante lineal produce el valor más alto.

2.5 Linealidad de la frontera de decisión

La frontera de decisión entre dos clases es el conjunto de puntos donde sus funciones discriminantes son iguales. Como estas funciones son lineales en x (al compartir la misma matriz de covarianza), la diferencia entre dos funciones discriminantes también es una función lineal, por lo que igualarla a cero produce un hiperplano: una recta en dos dimensiones, un plano en tres dimensiones, y así sucesivamente. De ahí que la frontera de decisión de LDA sea siempre lineal.

2.6 Ventajas

- Modelo simple, con pocos parámetros a estimar (una sola matriz de covarianza), lo que reduce el riesgo de sobreajuste, especialmente con muestras pequeñas.
- Buen desempeño cuando las clases están razonablemente separadas y el supuesto de covarianza común es plausible.
- Es computacionalmente eficiente y fácil de interpretar, ya que las fronteras son lineales.

2.7 Limitaciones

- Su desempeño se degrada si las clases tienen covarianzas verdaderamente distintas, ya que el supuesto de homocedasticidad no se cumple.
- Al ser un modelo lineal, no puede capturar relaciones cuadráticas o fronteras curvas entre clases.
- Es sensible a la presencia de outliers, que pueden distorsionar la estimación de la covarianza compartida.

2.8 Aplicaciones

LDA se utiliza ampliamente en reconocimiento de patrones (por ejemplo, reconocimiento facial), diagnóstico médico basado en biomarcadores, clasificación de productos según variables químicas o físicas (como en el presente trabajo con el Wine Dataset), y como técnica de reducción de dimensionalidad supervisada previa a otros algoritmos de clasificación.

3. Análisis Discriminante Cuadrático (QDA)

3.1 Definición

El Análisis Discriminante Cuadrático (QDA) es una generalización de LDA que relaja el supuesto de covarianza compartida: cada clase puede tener su propia matriz de covarianza. Esto permite que el modelo capture diferencias en la dispersión y orientación de los datos entre clases, a costa de estimar más parámetros.

3.2 Supuestos

QDA mantiene el supuesto de normalidad multivariante dentro de cada clase y la independencia de las observaciones, pero elimina el supuesto de igualdad de covarianzas entre clases: cada clase k tiene su propia matriz de covarianza Σ_k .

3.3 Covarianza distinta por clase

Cada clase posee su propia matriz de covarianza porque QDA no impone ninguna restricción de igualdad entre clases; simplemente estima, para cada una, la matriz de covarianza muestral de sus propias observaciones. Esto permite modelar de forma más fiel situaciones en las que unas clases están más dispersas o tienen una orientación distinta en el espacio de variables que otras.

3.4 Frontera cuadrática

Al no compartir la matriz de covarianza, los términos cuadráticos en x de la función discriminante ya no se cancelan al comparar dos clases. Por lo tanto, la diferencia entre las funciones discriminantes de dos clases contiene términos de segundo grado en las variables predictoras, lo que produce fronteras de decisión curvas: elipses, parábolas o hipérbolas, según la relación entre las covarianzas de las clases involucradas (Hastie et al., 2009).

3.5 Ventajas frente a LDA

- Mayor flexibilidad: puede ajustarse mejor cuando las clases tienen dispersión o forma claramente distinta.
- Puede lograr un menor error de clasificación cuando el supuesto de covarianza común de LDA no se cumple en la realidad.

3.6 Desventajas

- Requiere estimar una matriz de covarianza completa por cada clase, lo que aumenta considerablemente el número de parámetros, en especial con muchas variables predictoras.
- Mayor riesgo de sobreajuste cuando el número de observaciones por clase es pequeño en relación al número de variables.
- Es más costoso computacionalmente y menos interpretable que LDA.

3.7 Conjuntos de datos que favorecen su uso

QDA resulta favorable en conjuntos de datos con un número suficientemente grande de observaciones por clase (para estimar covarianzas de forma confiable) y en los que existe evidencia previa —visual o estadística— de que la dispersión de las variables difiere claramente entre clases, como ocurre en algunos problemas de bioinformática, reconocimiento de imágenes o clasificación de señales con grupos heterogéneos.

4. Metodología de Implementación

Para la parte práctica se utilizó el Wine Dataset, disponible en scikit-learn (`sklearn.datasets.load_wine`), sin aplicar ningún tratamiento previo sobre los datos. El conjunto contiene 178 observaciones de vinos provenientes de tres cultivares distintos, descritas mediante 13 variables químicas continuas (alcohol, ácido málico, flavonoides, intensidad de color, prolina, entre otras). No se encontraron valores faltantes y las tres clases están razonablemente balanceadas.

Se realizó una partición estratificada del 70% para entrenamiento y 30% para prueba, manteniendo la proporción de clases en ambos subconjuntos. No se aplicó estandarización adicional, respetando la consigna de trabajar con el dataset sin tratamiento; esta decisión se documenta también en el cuaderno de Colab. Se entrenaron un modelo `LinearDiscriminantAnalysis` (`solver='svd'`, adecuado para un número moderado de variables predictoras) y un modelo `QuadraticDiscriminantAnalysis` con sus parámetros por defecto de scikit-learn.

5. Resultados y Comparación

La siguiente tabla resume las métricas obtenidas sobre el conjunto de prueba para ambos modelos:

Modelo	Accuracy	Precisión (macro)	Recall (macro)	F1-score (macro)
LDA	0.981	0.982	0.984	0.983
QDA	1.000	1.000	1.000	1.000

Ambos modelos alcanzaron un desempeño muy alto sobre el Wine Dataset, con QDA logrando una clasificación perfecta sobre el conjunto de prueba y LDA muy cerca de dicho resultado. Esto sugiere que las tres clases de cultivares están bien separadas en el espacio de las 13 variables químicas, y que la mayor flexibilidad de QDA le permite ajustar de forma más precisa la frontera de decisión, posiblemente porque las clases no comparten exactamente la misma dispersión en algunas de las variables. El tiempo de entrenamiento fue muy bajo en ambos casos, dado el tamaño reducido del dataset, con una diferencia mínima a favor de LDA. Al graficar las fronteras de decisión usando dos variables (`flavanoids` y `color_intensity`), se observó que LDA genera fronteras rectas mientras que QDA genera fronteras curvas que se ajustan mejor a la forma de cada grupo de puntos, coherente con lo esperado teóricamente.

6. Conclusiones

- 1 El comportamiento de LDA en el Wine Dataset confirma que asumir una covarianza compartida entre cultivares es una simplificación razonable, dado su alto desempeño con fronteras lineales.
- 2 El comportamiento de QDA muestra que permitir covarianzas distintas por clase puede mejorar aún más la separación entre grupos cuando existe heterogeneidad real en la dispersión de las variables.
- 3 La influencia de los supuestos estadísticos es determinante: la forma de la frontera (lineal o cuadrática) es consecuencia directa de asumir o no una covarianza común, y no una elección arbitraria del algoritmo.

- 4 La comparación de resultados evidencia que, en datasets pequeños y bien separados como este, la diferencia práctica entre LDA y QDA puede ser mínima, aunque QDA tiende a tener ventaja cuando puede estimar covarianzas confiables por clase.
- 5 En aplicaciones prácticas, la elección entre LDA y QDA debe basarse en el tamaño muestral disponible por clase y en evidencia exploratoria sobre la homogeneidad o heterogeneidad de la dispersión entre clases, priorizando LDA cuando los datos son escasos y QDA cuando se dispone de suficientes observaciones para justificar su mayor flexibilidad.

Referencias

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2nd ed.). Springer.
- Scikit-learn developers. (2024). Linear and Quadratic Discriminant Analysis. Documentación oficial de scikit-learn.
- Aeberhard, S., & Forina, M. (1991). Wine Dataset. UCI Machine Learning Repository.